



MÓDULO 4 · AULA 27

# Aula 27

## Introdução: Data Science e Testes

---

Por que qualidade e testes são tão importantes quando o produto é...  
dado.

*Instrutor: Douglas Adriano Queiroz*

# O que vamos ver hoje



## O que é Data Science

Do dado bruto ao insight



## Ferramentas

Python, Altair AI Studio e cia.



## Por que testar?

Garbage in, garbage out



## O que se testa em DS

Código, dado e modelo



## DS × software comum

O que muda no teste



## Casos reais

Quando o dado engana

# O que é Data Science?

É transformar dados brutos em decisões: coletar, limpar, analisar, modelar e comunicar.

**Dado bruto:** planilhas, logs, bancos — muitas vezes sujos e incompletos.

**Análise:** encontrar padrões e responder perguntas do negócio.

**Modelo (ML):** aprender com os dados para prever ou classificar.

**Entrega:** gráficos, relatórios, dashboards e APIs que geram valor.



## Analogia da cozinha

Data Science é cozinhar: os dados são os ingredientes crus, a limpeza é lavar e cortar, o modelo é a receita e o insight é o prato pronto. E o bom cozinheiro PROVA em cada etapa — testar é isso: provar antes de servir.



**Leve daqui:** DS vira dado em decisão — e cada etapa precisa ser 'provada'.

# Ferramentas do ecossistema



## Python + pandas

A linguagem nº 1 de dados; pandas manipula tabelas (DataFrames).



## Jupyter Notebook

Ambiente para explorar dados e mostrar análises passo a passo.



## scikit-learn

Biblioteca de machine learning (treinar e avaliar modelos).



## Altair AI Studio

Plataforma visual (arrastar-e-soltar) de ciência de dados — o antigo RapidMiner.



## SQL

Buscar e conferir os dados na fonte (lembra o Bônus B1).



## Matplotlib / Power BI

Visualização de dados e dashboards.

# Big Data e a nuvem de dados

Às vezes o dado é grande, rápido e variado demais para caber numa planilha ou num PC — isso é Big Data.

**Os 3 Vs:** Volume (muito dado), Velocidade (chega rápido) e Variedade (formatos diferentes).

**Onde guardar:** plataformas de dados na nuvem — ex.: Snowflake, Google BigQuery, Databricks.

**Snowflake:** um 'data warehouse' na nuvem: guarda bilhões de linhas, escala sob demanda e se consulta com SQL.

**E o teste?** validamos a qualidade dos dados EM ESCALA (o Great Expectations roda sobre Snowflake/BigQuery) e testamos os pipelines de carga (ETL/ELT).



## Analogia do armazém

Se os dados da sua casa cabem num armário (uma planilha), Big Data é um armazém gigante: você não guarda tudo em casa, aluga um galpão na nuvem (Snowflake) que cresce quando precisa. E, como em todo armazém, um inspetor confere a qualidade do que entra.



**Leve daqui:** Big Data mora na nuvem (ex.: Snowflake); testar a qualidade dos dados vale ainda mais em escala.

# Problemas reais de Data Science no mercado



## Churn (cancelamento)

Prever quem vai cancelar a assinatura para agir antes. O caso mais clássico do mercado.



## Detecção de fraude

Identificar transações suspeitas de cartão em tempo real.



## Risco de crédito

Prever inadimplência para decidir a concessão de crédito.



## Previsão de demanda

Estimar vendas/estoque para não faltar nem sobrar.



## Recomendação

Sugerir produtos/filmes (o 'quem viu isso também viu').



## Análise de sentimento

Descobrir se avaliações e comentários são positivos ou negativos.

# Por que testar em Data Science?

**Se o dado entra errado, a conclusão sai errada — por mais bonito que seja o gráfico.**

**Testar o código:** as funções de limpeza e transformação fazem o que prometem?

**Testar o dado:** está completo, no formato e na faixa certa? (o dado também 'tem bugs').

**Testar o modelo:** acerta o suficiente? não está 'colando' (data leakage)?

**Impacto:** decisões de negócio, crédito, saúde e contratação dependem disso.



## Analogia da casa

Um relatório com um dado de valor em centavos tratado como reais mostra a empresa 100× mais rica. O gráfico fica lindo — e a decisão, desastrosa. Testar o dado evita isso.



**Leve daqui:** Em DS testamos três coisas: o código, o DADO e o modelo.

# Testando o DADO com pandera (exemplo)

Assim como o pytest testa o código, o pandera 'testa' o dado: você declara as regras e ele confere cada linha.

```
validar_dados.py

import pandas as pd
from pandera import Column, Check

schema = pd.DataFrameSchema({
    'idade': Column(int, Check.in_range(0, 120)), # idade plausível
    'email': Column(str, Check.str_matches(r'.+@.+')),
    'salario': Column(float, Check.ge(0)), # não pode ser negativo
    'cidade': Column(str, nullable=False), # campo obrigatório
})

schema.validate(df) # passa se ok; lança erro apontando a linha se violar
```



**Leve daqui:** Com o pandera, as regras do dado viram testes automáticos — dado ruim é barrado na entrada.



# Teste comum × teste em Data Science



## Software tradicional

- Entrada → saída determinística.
- Mesma entrada, mesma saída sempre.
- Teste: resultado esperado fixo.



## Data Science / ML

- Resultado é probabilístico (um modelo 'acerta X%').
- Depende dos dados, que mudam com o tempo.
- Teste: por faixa/limiar e qualidade do dado.



**Leve daqui:** Em DS, além de 'passou/falhou', testamos qualidade de dado e métricas por limiar.

# Quando o dado (ou o modelo) engana

Modelos e análises mal testados já causaram decisões injustas e caras.



## Recrutamento enviesado

Uma grande empresa abandonou uma IA de currículos que aprendeu a preferir homens — porque os dados históricos eram enviesados. Lição: teste viés e qualidade dos dados de treino.



## Modelo que 'colou' (data leakage)

Modelos que parecem ótimos no teste e falham na vida real porque 'viram' sem querer a resposta durante o treino. Lição: separe treino/teste e teste o vazamento.



**Leve daqui:** Dado enviesado ou vazamento passam despercebidos sem teste — e viram decisão errada.



# Resumão da aula



Data Science transforma dado bruto em decisão (coletar, limpar, modelar, comunicar).



Ferramentas: Python/pandas, Jupyter, scikit-learn, Altair AI Studio (RapidMiner), SQL, viz.



Garbage in, garbage out: dado ruim gera conclusão ruim.



Em DS testamos o código, o DADO e o modelo.



Diferente do software comum, avaliamos por faixa/limiar e qualidade de dado.



Dado enviesado e data leakage causam decisões injustas — teste-os.



# Glossário da aula

**Data Science** — Transformar dados em decisões e previsões

**DataFrame** — Tabela de dados (linhas × colunas) do pandas

**pandas** — Biblioteca Python para manipular tabelas

**Jupyter** — Ambiente interativo (notebook) para análise

**scikit-learn** — Biblioteca de machine learning em Python

**Altair AI Studio** — Plataforma visual de ciência de dados (antigo RapidMiner)

**Big Data** — Dados grandes/rápidos/variados demais para um PC ou planilha

**Snowflake** — Data warehouse (armazém de dados) na nuvem, consultado com SQL

**Modelo (ML)** — Programa que aprende com dados para prever/classificar

**Data leakage** — Vazamento: o modelo 'vê' a resposta no treino

**Viés (bias)** — Distorção que torna o modelo injusto/incorreto



# Referências e para aprofundar

**Pandas / scikit-learn.** Bases da manipulação de dados e ML em Python.

**Docs oficiais.** [pandas.pydata.org](https://pandas.pydata.org) · [scikit-learn.org](https://scikit-learn.org) · [docs.pytest.org](https://docs.pytest.org) · [greatexpectations.io](https://greatexpectations.io) · [rapidminer.com](https://rapidminer.com)

**Trilha do curso:** Data Science e Testes — Projeto Social Garapuvu 2026.