



MÓDULO 4 · AULA 31

Aula 31

Testar modelos de ML e Desafio Final da trilha

Boas práticas de teste de modelo — e o projeto que fecha a trilha.

Instrutor: Douglas Adriano Queiroz

O que vamos ver hoje



Testar modelos

Métricas, leakage, drift



Boas práticas

Reprodutível e justo



Desafio Final

O projeto da trilha



As tarefas

Do dado à API testada



Entregáveis

O que enviar



Avaliação

Como será corrigido

Como testar um modelo de ML

Um modelo não acerta 100% — testamos por limiar e cuidamos das armadilhas.

Métrica com limiar: ex.: acurácia/F1 $\geq 0,80$ no conjunto de teste, senão o build falha.

Sem data leakage: separe treino/teste; nunca use info do futuro ou do alvo nas features.

Reprodutibilidade: fixe a seed e versione dados e modelo (ex.: DVC) — mesmo resultado sempre.

Drift: em produção, monitore se os dados mudaram (o modelo 'envelhece').



Analogia da escola

Testar o modelo é como avaliar um aluno: a prova (teste) tem que ser diferente da lista de exercícios (treino), senão ele só decorou (leakage). E exigimos uma nota mínima para aprovar (limiar).



Leve daqui: Modelo se testa por limiar de métrica, sem leakage, de forma reprodutível.

Boas práticas de teste em Data Science



Fixe a seed

random_state garante o mesmo resultado a cada execução.



Separe treino/teste

Avalie no que o modelo nunca viu.



Evite leakage

Nada do alvo/futuro dentro das features.



Valide o dado

pandera/GE antes de treinar (lixo não entra).



Cheque viés

O modelo é justo entre grupos?



Documente

Dados, versão do modelo e métricas no README.



PROJETO QUE FECHA A TRILHA

Desafio Final — Data Science e Testes

O desafio: prever churn (cancelamento) de clientes

Você recebe um CSV de clientes de uma empresa de assinatura e deve prever quem vai CANCELAR (churn) — o caso mais comum de Data Science no mercado.

Dado: clientes.csv: tempo de casa (meses), plano, valor mensal, uso, chamados ao suporte e 'cancelou' (sim/não).

Por que importa: reter um cliente é bem mais barato que conquistar um novo — prever o churn vale dinheiro.

Objetivo: pipeline reproduzível: carregar → validar → limpar → treinar → servir → testar.

Meta: dados validados, testes verdes e $F1 \geq 0,75$; faça em código (pytest) OU visual (Altair AI Studio).



Como apresentar

Mostre o pipeline rodando: a validação barrando um dado ruim, os testes verdes, a API prevendo se um cliente vai cancelar e a métrica acima do limiar. Para praticar com dado real, use o dataset público 'Telco Customer Churn' (Kaggle).



Leve daqui: Projeto ponta a ponta: do CSV de clientes à API que prevê o churn, com qualidade comprovada.

As tarefas do desafio

1. Explorar e validar



Carregar clientes.csv; validar schema, nulos e faixas (pandera/GE).

2. Limpar (testável)



Funções de limpeza/feature com testes unitários (pytest).

3. Treinar e avaliar



scikit-learn; separar treino/teste; $F1 \geq 0,75$ (com seed fixa).

4. Servir por API



FastAPI: POST /prever recebe o cliente e retorna a chance de churn.

5. Testar tudo



Unit + validação de dado + métrica com limiar + endpoint da API.

6. Automatizar (CI)



GitHub Actions roda os testes a cada push.

A suíte de testes esperada

```
tests/
test_limpeza.py      # unit: funções de limpeza/feature
test_dados.py        # validação de esquema/faixas (pandera)
test_modelo.py        # métrica: assert f1 >= 0.75
test_api.py          # endpoint /prever: 200, formato, borda 400

# rodar tudo:
$ pytest --maxfail=1 -q
# no CI (github/workflows/ci.yml): pytesta cada push
```



Leve daqui: Quatro frentes de teste: limpeza, dado, modelo e API — todas verdes.

Entregáveis e avaliação



Repositório

Código ou processo do Altair AI Studio, testes e README.



Relatório de métricas

F1/acurácia no teste + matriz de confusão.



Testes verdes

Unit, validação de dado, métrica e API passando (no CI).



Qualidade do dado

Validação barrando dado inválido, sem leakage, seed fixa.



API funcionando

POST /prever responde com previsão válida.



Apresentação

Mostrar o pipeline rodando e explicar as decisões.



Resumão — e parabéns pela trilha!



Modelo se testa por limiar de métrica (ex.: $F1 \geq 0,75$), sem data leakage.



Reprodutibilidade: seed fixa e versionar dados/modelo.



O Desafio (churn de clientes): do CSV à API, com pipeline validado e testado.



Tarefas: explorar/validar, limpar, treinar, servir, testar, automatizar.



Entregue: repositório, testes verdes no CI, métricas e API funcionando.



Você aprendeu a testar o código, o DADO e o modelo — o tripé da qualidade em DS.



Glossário da aula

Acurácia — % de previsões corretas

Precisão/Recall — Qualidade das previsões positivas / cobertura

F1-score — Equilíbrio entre precisão e recall (0 a 1)

Limiar (threshold) — Nota mínima que a métrica deve atingir

Treino/Teste — Divisão dos dados para treinar e avaliar

Data leakage — Vazamento da resposta para dentro do treino

Data drift — Mudança da distribuição dos dados em produção

Matriz de confusão — Tabela de acertos e erros por classe

DVC — Controle de versão de dados e modelos

Reprodutibilidade — Mesmo processo gera o mesmo resultado



Referências e para aprofundar

scikit-learn — Model evaluation. Métricas e validação de modelos.

Dataset para praticar: Telco Customer Churn (Kaggle) — problema real de cancelamento.

Estrutura do desafio. Inspirada no Desafio Final de QA — mesma lógica, aplicada a dados.

Docs oficiais. pandas.pydata.org · scikit-learn.org · docs.pytest.org · greatexpectations.io · rapidminer.com

Trilha do curso: Data Science e Testes — Projeto Social Garapuvu 2026.